



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Informe Trabajo Práctico 01

Laboratorio de Datos

Integrante	LU	Correo electrónico
Rozas Chavez, Antuanette Carolina	571/23	antuanetterozas@gmail.com
Madril, Joaquin Leandro	109/25	madriljoaquin@gmail.com
Fernández Fazio, Adrián Patricio	938/24	adrianfernandezfazio@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 +11) 4576-3300

<http://www.exactas.uba.ar>


Resumen

Introducción

El objetivo del presente trabajo es clarificar si existe cierta relación entre las enfermedades que llevan a la muerte, variables demográficas y de acceso a la salud, y si hubo variaciones a lo largo del tiempo. Para abordar el desafío tendremos que sanear la información provista que presenta inconvenientes tales como tablas anidadas, encabezados dentro de las tuplas, inconsistencias e información innecesaria. Tendremos que relacionar toda la información confeccionando un Diagrama Entidad Relación para, a partir del mismo crear un Modelo Relacional. Este modelo relacional será el insumo para crear una base de datos relacional, la cual será la herramienta de consulta que utilizaremos para abordar el objeto de estudio, y las preguntas que se desprenden del mismo. Utilizaremos recursos técnicos como Python, con sus módulos pandas, numpy y duckdb para modelar la base de datos. Para las consultas a dicha base utilizaremos SQL, y para graficar los módulos de Python matplotlib y seaborn. El presente informe continúa con una sección "Procesamiento de Datos" donde explicaremos la metodología utilizada para sanear y consolidar la información. Un apartado "Decisiones tomadas" donde documentaremos el criterio que utilizamos a la hora de resolver situaciones surgidas de la problemática. En la sección "Análisis de Datos" responderemos las preguntas consignadas por los docentes. Y para finalizar una sección con las conclusiones que se desprenden del presente trabajo.


Procesamiento de Datos

Para resolver los problemas proponemos el siguiente Diagrama Entidad-Relación:




Aclaración: Departamento es entidad débil porque se repiten los id para distintas provincias por lo que se identifican con id_provincia e id_departamento.

A continuación definimos los esquemas del Modelo Relacional del DER:



Dependencias Funcionales



Formas Normales

1FN: Todas las tablas están en primera forma normal ya que los atributos son de valores átomicos y no hay relaciones anidadas.

2FN: En todos los esquemas los atributos no primos dependen completamente de la/s claves por lo tanto cumple la segunda forma normal.

3FN: Para cada esquema solo tenemos una dependencia funcional que tiene del lado derecho a la clave por lo que cumple la tercera forma normal.

Formas normales de las tablas Establecimientos de salud y Defunciones

Primero analizamos las formas normales en que se encuentra la tabla de Establecimientos:

1FN: Se cumple la primera forma normal debido a que el dominio de los atributos solo incluyen valores atómicos y no hay ningún atributo que sea clave parcial de una relación anidada.

2FN: La única clave es establecimiento_id (ya que los demás atributos tienen valores repetidos o nulos) y como todo atributo no primo (todos los demás) dependen completamente de la clave se cumple la segunda forma normal.

3FN: No cumple con la tercera forma normal ya que tenemos las siguientes dependencias funcionales: $provincia_id \rightarrow provincia_nombre$, $localidad_id \rightarrow localidad_nombre$, entre otras, donde el atributo del lado izquierdo no es super clave y el del lado derecho no es primo.

Ahora para la tabla de Defunciones:

1FN: También cumple la primera forma normal ya que los atributos solo tienen valores atómicos y no hay relaciones anidadas.

2FN: La clave de esta tabla es compuesta y es la siguiente:

(anio, jurisdiccion_residencia_id, cie10_causa_id, sexo_id, muerte_materna_id, grupo_edad)

Podemos notar que hay atributos no primos que dependen parcialmente de la clave:

- $jurisdiccion_residencia_id \rightarrow jurisdiccion_residencia_nombre$
- $muerte_materna_id \rightarrow muerte_materna_clasificacion$
- $cie10_causa_id \rightarrow cie10_clasificacion$

Por lo que no cumple la segunda forma normal.

3FN: No cumple con la segunda entonces no puede cumplir con la tercera forma normal.

Calidad de datos

La tabla **Defunciones** tiene valores NaN en las columnas:

- jurisdiccion_residencia_nombre
- muerte_materna_id
- muerte_materna_clasificacion
- cie10_clasificacion

El **atributo de calidad** afectado es el de **Compleitud**, no están presentes todos los valores para representar la realidad. Se trata de un problema asociado a la **Instancia**, datos que no han sido almacenados con la precisión necesaria.

Utilizando la técnica GQM podemos cuantificar la magnitud del problema:

Objetivo: El dato correspondiente al nombre de la jurisdicción donde ocurrió el fallecimiento está completo

Pregunta: Cuál es la proporción de defunciones que tienen el dato correspondiente a jurisdiccion_residencia_nombre con valores NaN?

Métrica:

Métrica Nan = $\frac{\text{cantidad de defunciones con el campo jurisdiccion_residencia_nombre como NaN}}{\text{cantidad total de defunciones}}$

Métrica Nan = 0.006

Objetivo: El dato correspondiente a la causa del fallecimiento está completo

Pregunta: Cuál es la proporción de defunciones que tienen el dato correspondiente a cie10_clasificacion con valores NaN?

Métrica:

Métrica Nan causa = $\frac{\text{cantidad de defunciones con el campo cie10_clasificacion como NaN}}{\text{cantidad total de defunciones}}$

Métrica Nan causa = 0.002

Claramente se trata de un caso de falta de rigor en la carga de datos. Al ser ambos porcentajes menores al 1% de la cantidad total de tuplas, decidimos descartarlos del cuerpo de datos a procesar. Las columnas relacionadas a la muerte materna no eran relevantes para este trabajo por lo cual lo más conveniente fue eliminarlas.

Una forma de evitar este tipo de errores es implementar una interface que contenga un formulario del tipo menú desplegable, que permita seleccionar sólo una opción de todas las disponibles, y no habilite el registro nulo.

La tabla **Instituciones** tiene registros mal cargados en la columna **id_provincia**

El **atributo de calidad** afectado es el de la **Consistencia**, hay contradicciones entre distintos datos almacenados. Se trata de un problema asociado a **errores de Software**, probablemente un problema de interface poco amigable.

Utilizando la técnica GQM podemos cuantificar la magnitud del problema:

Objetivo: El dato correspondiente al atributo **id_provincia** se corresponde a una única provincia por cada id suministrado

Pregunta:Cuál es la proporción de id's incorrectamente cargados?

Métrica:

$$\text{Métrica registros} = \frac{\text{cantidad de registros mal cargados}}{\text{cantidad total de instituciones}}$$

Métrica registros = 0.0001

Se trata de un caso donde una interface mal diseñada no muestra un desplegable que para cada provincia asigne el Id correspondiente. El ratio es insignificante por lo cual la solución más razonable era eliminar los registros erróneos.


Decisiones tomadas

Las tablas de **censos** tenían varios desafíos técnicos que obligaron a tomar varias decisiones. Había encabezados y tablas anidadas que tuvieron que ser adaptadas a un formato manejable para la resolución del trabajo. Eliminamos columnas que no eran relevantes para el dominio del problema, como así también secciones donde se sumaban los totales de distintas categorías.


La tabla **defunciones** tenía una diversidad de categorías que tuvo que ser adaptada a una lista más manejable provista por los docentes. Había muchas columnas que no eran relevantes para el presente trabajo y decidimos descartarlas. Eliminamos tuplas que tenían valores null o similares en las columnas **jurisdiccion_residencia_nombre**, **grupo_edad**, y **sexo**. Basamos nuestra decisión en que el total de todas estas tuplas representaba menos del 3,5% de las defunciones.

La tabla **instituciones** tenía columnas irrelevantes para el informe que fueron descartadas. Simplificamos la topología de las instituciones, ya que sólo nos interesaba saber si tenían **terapia intensiva**. Similarmente procedimos con el **financiamiento**, ya que lo importante era discriminar entre **estatal** o **privado**. Había inconsistencias en la columna **departamento_nombre** donde algunos registros figuraban como 'LA CAPITAL' y otros como 'CAPITAL'. Consolidamos todos estos casos a 'CAPITAL'. Para finalizar eliminamos registros que tenían mal cargado el dato de la ID de la provincia. Por ser sólo 5 tomamos esta decisión, ya que eran insignificantes dentro del cuerpo del total de datos disponibles.


Análisis de Datos




Se observa un incremento en la población a nivel país, pero mucho más significativo en la provincia de Santa Cruz




La enfermedades cardiovasculares como principal causa de defunción aumentan progresivamente. Los tumores se mantienen estables y se observa un crecimiento de las enfermedades pulmonares hasta superar la cantidad de defunciones por tumores. Tomar nota del impacto significativo del COVID en los años 2020, 2021.




Se observa un marcado crecimiento de las defunciones provocadas por enfermedades del sistema genitourinario, y una caída durante la pandemia tanto de estas últimas como de los fallecimientos por accidentes y causas externas.




Observamos una marcada caída de las defunciones por enfermedades relacionadas con la natalidad.




Destacamos que a pesar de las condiciones favorables de vida de la Ciudad Autónoma de Buenos Aires, presenta la tasa de defunciones cada mil habitantes más alta del país, lo que contrasta por ejemplo con Tierra del Fuego, que con condiciones de vida más hostiles consigue una tasa de mortalidad mucho menor.




En la Ciudad Autónoma de Buenos Aires, y en provincias como Buenos Aires, Córdoba, Misiones y San Luis, se observa una preponderancia marcada de las enfermedades del aparato circulatorio por sobre las enfermedades pulmonares.



Como era esperable existe una relación directa entre la edad y la cantidad de defunciones. Se verifica una mayor mortalidad en la población masculina en todos los rangos etarios.



No se observa una relación entre la cantidad de habitantes y la cantidad de establecimientos por departamento.



Nos interesó conocer la cantidad de establecimientos con terapia intensiva por provincia, normalizados cada mil habitantes. Se observa una baja densidad de los mismos en provincias como Buenos Aires, Santa Fe, Santiago del Estero, Santa Cruz y la Ciudad Autónoma de Buenos Aires.

Conclusiones